

UNIVERSIDAD NACIONAL DE MOQUEGUA
ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMAS E
INFORMATICA



**“COMPARACIÓN DE MODELOS DE CLUSTERING APLICADOS A LA
SEGMENTACIÓN DE PERFILES SOCIOECONÓMICOS EN ESTUDIANTES DE LA
UNIVERSIDAD NACIONAL DE MOQUEGUA, 2026.”**

PLAN DE TESIS

PRESENTADO POR:

LEO ENRIQUE PARI PUMA

ILO, MOQUEGUA – PERÚ

2026

Contenido

1. Datos Generales	6
1.1 Título.....	6
1.2 Datos del Investigador	6
1.3 Datos del Asesor de Tesis	6
1.4 Línea de Investigación	6
2. Problema de Investigación.....	6
2.1 Descripción de la realidad problemática	6
2.2 Formulación del problema de investigación	8
2.2.1 Problema general	8
2.2.2 Problemas específicos	8
2.3 Justificación	8
2.4 Objetivos	9
2.4.1 Objetivo general.....	9
2.4.2 Objetivos específicos	9
3. Marco teórico	10
3.1 Antecedentes del problema	10
3.2 Bases teóricas.....	12
3.2.1 Características Socioeconómicas	12
3.2.2 Segmentación Socioeconómica.....	14
3.2.3 Analítica Educativa	16
3.2.4 Minería de datos educativa	17

3.2.5 Clustering.....	17
3.3 Definición de términos.....	23
3.3.1 Aprendizaje Automático	23
3.3.2 Clúster	23
3.3.3 Variable socioeconómica	23
3.3.4 Métrica de evaluación	24
3.3.5 Toma de decisiones académicas	24
3.3.6 Apoyo institucional	24
3.3.7 Dataset.....	24
3.3.8 Codificación de variables.....	24
3.3.9 Perfil socioeconómico.....	25
3.3.10 Outlier	25
4. Metodología	25
4.1 Tipo y Nivel de Investigación.....	25
4.2 Diseño de Investigación	26
4.3 Operación de variables.....	26
4.3.1 Variable 1.....	26
4.3.2 Variable 2.....	28
4.4 Población y Muestra	30
4.4.1 Población.....	30
4.4.2 Muestra	30

4.5 Técnicas e instrumentos para la recolección de datos.....	30
4.5.1 Técnicas	30
4.5.2 Instrumentos.....	31
4.6 Validación de los instrumentos	31
4.7 Métodos y técnicas para la presentación y análisis de datos.....	32
4.8 Propuesta Metodológica.....	33
4.8.1 Comprensión de los datos	34
4.8.2 Preparación de los datos.....	34
4.8.3 Modelado	35
4.8.4 Evaluación.....	35
5. Aspectos Administrativos	36
5.1 Cronograma de actividades.....	36
5.2 Presupuesto	37
5.2.1 Recursos Humanos.....	37
5.2.2 Bienes y Servicios.....	37
5.2.3 Plan Presupuestal	38
5.2.4 Fuentes de Financiamiento.....	39
6. Bibliografía	39
7. ANEXO	1

INDICE DE ILUSTRACIONES

Ilustración 1. Metodología CRISP-DM	33
---	----

Ilustración 2. Metodología adaptada para la investigación.....	36
--	----

INDICE DE TABLAS

Tabla 1. Resumen de Antecedentes	12
Tabla 2. Variable 1 – Segmentación y Perfiles	26
Tabla 3. Variable 2 – Características Socioeconómicas	28
Tabla 4. Cronograma de Actividades.....	36
Tabla 5. Recursos Humanos	37
Tabla 6. Bienes y Servicios.....	37
Tabla 7. Plan presupuestal	38

1. Datos Generales

1.1 Título

“Comparación de modelos de clustering aplicados a la segmentación de perfiles socioeconómicos en estudiantes de la Universidad Nacional de Moquegua, 2026.”

1.2 Datos del Investigador

Nombre: Leo Enrique Pari Puma

Escuela Profesional: Ingeniería de Sistemas e Informática

Código Universitario: 2021204119

Correo Electrónico: 3nrique.2003@gmail.com

1.3 Datos del Asesor de Tesis

Dra. Vaneza Flores Gutierrez

1.4 Línea de Investigación

Inteligencia Artificial

2. Problema de Investigación

2.1 Descripción de la realidad problemática

A nivel global, la educación superior enfrenta el desafío de garantizar condiciones equitativas de acceso, permanencia y desarrollo académico para estudiantes que provienen de contextos socioeconómicos diversos. El nivel de ingresos del hogar, el acceso a tecnología, la conectividad, la ubicación geográfica y la escolaridad de los padres generan diferencias concretas en las posibilidades de formación universitaria.

El acceso a la educación superior sigue siendo desigual según el ingreso familiar, lo que lleva a las instituciones a identificar con mayor precisión las condiciones socioeconómicas de sus estudiantes para detectar grupos con necesidades distintas y diseñar estrategias de apoyo más ajustadas a cada caso (UNESCO, 2022).

En América Latina y el Caribe, la expansión de la matrícula universitaria no redujo las brechas socioeconómicas entre estudiantes. En 2020 asistían a la educación superior alrededor de 28,9 millones de jóvenes y adultos en la región, pero esa cifra coexistía con diferencias persistentes de origen socioeconómico, conectividad, procedencia territorial y condiciones familiares (CRES+5, 2024). El Banco Mundial señala que en América Latina y el Caribe una de cada cuatro personas vive con menos de 6,85 dólares diarios, evidenciando que la pobreza sigue siendo una condición estructural que puede limitar las trayectorias educativas y afectar las posibilidades de permanencia y éxito académico de los estudiantes universitarios (Rodríguez Castelán, Winkler, García García, & Castellanos, 2024).

El Reporte Nacional de Seguimiento del Proyecto Educativo Nacional indica que, al 2024, persisten desigualdades asociadas a pobreza, escolaridad parental, conectividad y accesibilidad. La pobreza reduce en 17,9 puntos porcentuales la probabilidad de ingresar a la educación superior universitaria; la ausencia de estudios superiores en los padres la reduce en 15,2 puntos porcentuales. Ambos datos confirman que las condiciones socioeconómicas siguen condicionando las trayectorias educativas de los jóvenes peruanos (CNE, 2024).

Según el Reporte de Seguimiento 2024 del Proyecto Educativo Nacional para Moquegua, el 77,9% de los hogares contaba en 2024 con acceso simultáneo a agua segura, saneamiento, electricidad e internet, cifra superior al promedio nacional de 68,1%; sin embargo, ese porcentaje cayó respecto al 78,6% registrado en 2023 (CNE, 2024).

Frente a esta situación, es necesario aplicar técnicas de análisis de datos que permitan descubrir patrones ocultos dentro de la información socioeconómica estudiantil. Los algoritmos de clustering permiten agrupar registros con características similares sin necesidad de definir categorías previamente, lo que los convierte en una alternativa adecuada para identificar perfiles estudiantiles.

Por ello, la presente investigación busca evaluar algoritmos de clustering aplicados a la segmentación socioeconómica de estudiantes de la Universidad Nacional de Moquegua, con el propósito de identificar perfiles estudiantiles que contribuyan a la toma de decisiones académicas y de apoyo institucional.

2.2 Formulación del problema de investigación

2.2.1 Problema general

¿Cuál es el modelo de clustering más adecuado para la segmentación de perfiles socioeconómicos de los estudiantes de la Universidad Nacional de Moquegua, 2026?

2.2.2 Problemas específicos

- ¿Cuál es el desempeño de los modelos de clustering para la segmentación de perfiles socioeconómicos de los estudiantes de la Universidad Nacional de Moquegua, considerando las métricas de validación interna (coeficiente de silueta, índice Davies-Bouldin e índice Calinski-Harabasz)?
- ¿Qué perfiles socioeconómicos pueden identificarse a partir de la segmentación de la ficha socioeconómica de los estudiantes de la Universidad Nacional de Moquegua para apoyar la toma de decisiones institucionales?

2.3 Justificación

La presente investigación se justifica principalmente en la necesidad de examinar con mayor profundidad la información socioeconómica de los estudiantes de la Universidad Nacional de Moquegua. Factores como la situación económica familiar, el acceso a tecnología, el lugar de procedencia y las condiciones del entorno pueden influir de manera importante en el desempeño académico y en las oportunidades de desarrollo de los estudiantes.

En el plano teórico, este trabajo aportará conocimiento sobre cómo usar algoritmos de aprendizaje automático sin supervisión, especialmente métodos de clustering, para analizar información educativa. La investigación permitirá comprender mejor cómo aplicar modelos de clustering para descubrir tendencias ocultas en datos socioeconómicos, lo que será útil para el campo de la analítica y la minería de datos en educación.

Metodológicamente, el trabajo se justifica porque propone evaluar y comparar el desempeño de distintos algoritmos de clustering como K-Means, DBSCAN y el clustering jerárquico. Esta comparación permitirá seleccionar el algoritmo más adecuado para el tipo de datos disponibles y evitar clasificaciones arbitrarias de los estudiantes.

Por último, este estudio cobra especial relevancia porque se realiza con datos reales del contexto de la Universidad Nacional de Moquegua. Su objetivo no se limita a aplicar técnicas de clustering, sino a transformar información socioeconómica en conocimiento útil que pueda ayudar con la toma de decisiones académicas, el apoyo institucional y de gestión institucional.

2.4 Objetivos

2.4.1 Objetivo general

Comparar algoritmos de clustering aplicados a la segmentación socioeconómica de los estudiantes de la Universidad Nacional de Moquegua, con el fin de identificar perfiles estudiantiles.

2.4.2 Objetivos específicos

OE.1 Construir y evaluar modelos de clustering para la segmentación de perfiles socioeconómicos de los estudiantes de la Universidad Nacional de Moquegua, mediante la aplicación de métricas de validación interna como el coeficiente de silueta, el índice Davies-Bouldin y el índice Calinski-Harabasz.

OE.2 Identificar los perfiles socioeconómicos de los estudiantes de la Universidad Nacional de Moquegua mediante la aplicación de modelos de clustering, con el fin de apoyar la toma de decisiones institucionales.

3. Marco teórico

3.1 Antecedentes del problema

El estudio *Uncovering student profiles: An explainable cluster analysis approach to PISA 2022* de (Alvarez Garcia, Arenas Parra, & Ibar Alonso, 2022) buscó identificar perfiles de estudiantes a partir de los datos de PISA 2022, considerando uso y acceso a tecnología, género, rendimiento académico y aspiraciones educativas futuras. La metodología combinó preparación de datos, reducción dimensional, formación de grupos, categorización e interpretación asistida por inteligencia artificial explicable. Los datos provinieron de 30 800 estudiantes de España y 74 variables contextuales. Los resultados mostraron que el análisis de clúster permite detectar perfiles estudiantiles con suficiente precisión para orientar decisiones institucionales y diseñar programas educativos más ajustados a cada grupo.

Implementation of K-Means clustering on student learning achievements based on social economic and social related, es una investigación de (Lestari Siregar, Hidayanthi, & Dewa Sakti, 2024) en el que agruparon el rendimiento académico de estudiantes a partir de variables socioeconómicas: acceso a materiales de estudio, disponibilidad de computadoras, entorno familiar y apoyo educativo. La investigación combinó un diseño secuencial explicativo con minería de datos, aplicando K-Means para segmentar estudiantes según sus condiciones sociales y académicas. Los resultados identificaron grupos diferenciados con patrones claros de acceso tecnológico y soporte educativo. Los autores concluyen que el clustering ayuda a caracterizar las necesidades de distintos perfiles estudiantiles y a focalizar estrategias de intervención académica. El estudio es un antecedente directo del presente trabajo por usar el mismo algoritmo y variables de tipo socioeconómico.

Dentro de la investigación de (Antonio Vargas & Navarro Castillo, 2025) *Clusterización de perfiles emprendedores de estudiantes universitarios en la UNALM: un análisis con K-Means*, donde su objetivo fue clasificar las personalidades emprendedoras en universitarios mediante una metodología cuantitativa no experimental. El instrumento fue un cuestionario validado por la Fundación Wadhwani; el algoritmo K-Means operó sobre variables de sexo, edad y especialidad. El análisis produjo dos grupos con tendencias emprendedoras distintas y detectó asociación significativa entre esas variables y los perfiles obtenidos. El estudio muestra cómo K-Means se ha aplicado en universitarios peruanos para distinguir perfiles diferenciados dentro de una misma institución.

En la investigación *Aplicación del algoritmo K-Means en estudiantes universitarios del área de sistemas e informática para caracterizar la salud mental, durante el aislamiento en COVID-19*, los autores (Peralta Ascue, Merma Aroni, Chaves Vasquez, Soto Carrion, & Jimenez Mendoza, 2022) analizaron a estudiantes de la UTEA y la UNAMBA con K-Means para identificar perfiles según indicadores socioemocionales y académicos. Los resultados detectaron prevalencia de síntomas depresivos cercana al 60 % y agruparon a los estudiantes en perfiles con características y necesidades distintas. El estudio aporta evidencia de que el algoritmo funciona con poblaciones universitarias peruanas para segmentar grupos con condiciones diferenciadas dentro de una misma muestra.

Tabla 1. Resumen de Antecedentes

Autor / año	Objetivo	Metodología	Resultados	Conclusiones
Alvarez-Garcia et al. (2024)	Identificar y caracterizar perfiles estudiantiles a partir de datos de PISA 2022.	Análisis de clúster explicable: preprocesamiento, reducción de dimensionalidad, clustering e inteligencia artificial explicable (XAI).	Se encontraron perfiles diferenciados de estudiantes a partir de variables de uso de TIC, género, rendimiento académico y expectativas educativas.	El clustering combinado con XAI produce perfiles interpretables que orientan decisiones educativas concretas.
Siregar et al. (2024)	Agrupar los logros de aprendizaje de estudiantes considerando factores socioeconómicos y sociales.	Algoritmo K-Means aplicado sobre variables de condiciones sociales, económicas y recursos educativos.	Los grupos resultantes mostraron diferencias claras en logros de aprendizaje según condiciones socioeconómicas.	K-Means agrupa estudiantes con características similares, lo que facilita detectar qué necesidades académicas y tecnológicas comparte cada grupo.
Vargas y Navarro (2025)	Clasificar perfiles emprendedores de estudiantes universitarios de la UNALM.	Investigación cuantitativa no experimental con encuesta validada y algoritmo K-Means.	Se obtuvieron dos clústeres con tendencias emprendedoras distintas, asociados a género, edad y carrera.	El análisis identificó perfiles diferenciados en universitarios peruanos y mostró que variables demográficas básicas bastan para segmentarlos con K-Means.
Ascúe et al. (2022)	Caracterizar la salud mental de estudiantes universitarios del área de sistemas e informática durante el aislamiento por COVID-19.	Aplicación del algoritmo K-Means en estudiantes de la UTEA y UNAMBA, utilizando indicadores socioemocionales y académicos.	Los grupos difieren en nivel de afectación: cerca del 60 % de la muestra presentó síntomas depresivos.	El algoritmo distinguió subpoblaciones con necesidades distintas dentro del mismo contexto universitario peruano, lo que sugiere su utilidad para intervenciones focalizadas.

3.2 Bases teóricas

3.2.1 Características Socioeconómicas

Las características socioeconómicas comprenden el conjunto de atributos sociales, económicos, familiares y contextuales que describen las condiciones de vida de una persona o grupo social. Estas

características permiten comprender diferencias en el acceso a recursos, oportunidades y servicios, siendo ampliamente utilizadas en estudios educativos, sociales y económicos para identificar patrones y perfiles dentro de una población.

Según la Comisión Económica para América Latina y el Caribe (CEPAL, 2022), las condiciones socioeconómicas representan un conjunto de factores relacionados con ingresos, educación, empleo, vivienda, acceso a servicios básicos y recursos tecnológicos que influyen en las oportunidades de desarrollo de las personas. En el ámbito educativo, estas variables son relevantes porque pueden estar asociadas a diferencias en el acceso, permanencia y desempeño de los estudiantes.

3.2.1.a Factores Demográficos

Los factores demográficos corresponden a características generales que describen a los individuos dentro de una población, tales como edad, sexo, lugar de residencia y estado civil. Estas variables permiten contextualizar las diferencias existentes entre grupos de estudiantes y suelen utilizarse como variables de segmentación en estudios sociales y educativos.

Las variables demográficas son fundamentales para caracterizar poblaciones y analizar fenómenos asociados a desigualdad social, acceso a servicios y desarrollo humano (INEI, 2024).

3.2.1.b Factores Educativos del entorno familiar

El entorno familiar constituye uno de los principales elementos asociados al desarrollo académico de los estudiantes. Diversos estudios indican que el nivel educativo alcanzado por los padres influye en las expectativas educativas, el apoyo académico y las oportunidades de aprendizaje disponibles dentro del hogar.

Según el Consejo Nacional de Educación (CNE, 2024), la escolaridad de los padres continúa siendo una variable relevante para explicar diferencias en el acceso y permanencia de los jóvenes en la educación superior peruana.

3.2.1.c Factores Tecnológicos

El acceso a recursos tecnológicos constituye actualmente una dimensión importante de las condiciones socioeconómicas de los estudiantes. La disponibilidad de dispositivos digitales y conectividad influye directamente en el acceso a información, plataformas virtuales y recursos de aprendizaje.

3.2.1.d Factores de Vivienda y Servicios Básicos

Las condiciones de vivienda permiten evaluar el bienestar material de los hogares y constituyen indicadores ampliamente utilizados en estudios socioeconómicos. Aspectos como acceso a agua potable, saneamiento, electricidad e internet reflejan diferencias importantes en la calidad de vida de las familias.

De acuerdo con el Programa de las Naciones Unidas para el Desarrollo (PNUD, 2023), el acceso adecuado a servicios básicos es un componente fundamental para evaluar las condiciones de desarrollo humano y bienestar social.

3.2.2 Segmentación Socioeconómica

La segmentación socioeconómica es el proceso de clasificación o agrupación de una población en diferentes categorías o perfiles a partir de características sociales, económicas, familiares, tecnológicas o territoriales compartidas. Su finalidad es identificar grupos homogéneos que permitan comprender mejor las diferencias existentes dentro de una población y facilitar el análisis de sus necesidades, comportamientos o condiciones de vida. La segmentación consiste en dividir una población heterogénea en grupos más pequeños y homogéneos que comparten características similares. Aunque este concepto se originó en el ámbito del marketing, actualmente es ampliamente utilizado en áreas como la educación, las ciencias sociales y la ciencia de datos para analizar poblaciones complejas (Kotler & Keller, 2016).

3.2.2.a Importancia de la segmentación socioeconómica

Las poblaciones estudiantiles no son homogéneas. Los estudiantes pueden presentar diferencias significativas en aspectos económicos, sociales, familiares y tecnológicos que influyen en sus experiencias educativas.

Según la CEPAL, las desigualdades socioeconómicas continúan siendo uno de los principales factores que generan diferencias en las oportunidades de acceso y permanencia dentro de los sistemas educativos latinoamericanos (CEPAL, 2022).

Por ello, la segmentación socioeconómica permite:

- Identificar grupos con características similares.
- Comprender mejor la diversidad estudiantil.
- Detectar patrones ocultos en los datos.
- Facilitar estudios comparativos entre perfiles.
- Generar información útil para futuras estrategias institucionales.

3.2.2.b Variables utilizadas en Segmentación Socioeconómica

La segmentación socioeconómica se construye a partir de variables que describen las condiciones de vida de las personas.

De acuerdo con la CEPAL, las dimensiones más utilizadas para caracterizar la situación socioeconómica de una población incluyen:

- Factores económicos: Relacionados con la disponibilidad de recursos financieros (Ingreso familiar, Dependencia económica, Situación laboral, etc.).
- Factores educativos: Relacionados con el capital educativo del hogar (Nivel educativo del padre, Nivel educativo de la madre, Apoyo educativo familiar, etc.).
- Factores tecnológicos: Relacionados con el acceso a recursos digitales (Acceso a internet, Disponibilidad de computadora, Disponibilidad de dispositivos móviles, etc.).

- Factores de vivienda y servicios: Relacionados con las condiciones materiales del hogar (Tipo de vivienda, Acceso a agua potable, Acceso a saneamiento, Acceso a electricidad, etc.).
- Factores territoriales: Relacionados con la ubicación geográfica del estudiante (Zona urbana o rural, Distrito de procedencia, Distancia al centro de estudios, etc.).

3.2.2.c Segmentación Socioeconómica mediante Ciencia de Datos

La segmentación socioeconómica se realizaba mediante clasificaciones predefinidas elaboradas por especialistas o instituciones gubernamentales. Sin embargo, el crecimiento de los datos ha impulsado el uso de técnicas de minería de datos y aprendizaje automático para identificar grupos de forma automática.

Las técnicas de clustering permiten descubrir estructuras ocultas dentro de grandes volúmenes de datos sin necesidad de establecer categorías previas (Han, Kamber, & Pei , 2012).

3.2.2.d Perfiles Estudiantiles

Los perfiles de los estudiantes son descripciones de un conjunto de alumnos basadas en rasgos compartidos, tales como aspectos académicos, socioeconómicos, tecnológicos, familiares o de comportamiento. Estos perfiles pueden ser identificados y descritos a través de análisis de clústeres utilizando información educativa, lo que facilita la relación con elementos como acceso a tecnología, desempeño académico, género y aspiraciones educativas (Alvarez Garcia, Arenas Parra, & Ibar Alonso, 2022).

3.2.3 Analítica Educativa

La analítica educativa se encarga de recopilar, procesar, analizar e interpretar datos relacionados con los estudiantes y su entorno académico, con el propósito de mejorar la toma de decisiones tanto a nivel pedagógico como institucional.

La analítica del aprendizaje permite utilizar datos educativos para comprender y optimizar los procesos de enseñanza, aprendizaje y gestión institucional (Long & Siemens, 2011). En el contexto universitario, su aplicación puede contribuir a identificar perfiles estudiantiles, mejorar estrategias de acompañamiento académico y orientar programas de apoyo.

3.2.4 Minería de datos educativa

La minería de datos (Data Mining) consiste en el proceso de extraer patrones, relaciones y conocimiento útil a partir de grandes volúmenes de datos, mediante técnicas estadísticas, computacionales y de inteligencia artificial (Kalita, y otros, 2025).

En el ámbito educativo, conocida como Educational Data Mining (EDM), se aplica para analizar información generada en los entornos de enseñanza y aprendizaje (calificaciones, comportamiento en plataformas virtuales, datos socioeconómicos, etc.), con el objetivo de identificar patrones ocultos, predecir el rendimiento estudiantil, detectar estudiantes en riesgo y apoyar la toma de decisiones institucionales más informadas y personalizadas (Kalita, y otros, 2025).

3.2.5 Clustering

El clustering o análisis de conglomerados es una técnica de aprendizaje no supervisado cuyo objetivo es agrupar objetos o registros similares dentro de un mismo grupo (clúster) y diferenciarlos de los elementos pertenecientes a otros grupos. A diferencia de los métodos supervisados, el clustering no requiere etiquetas o categorías predefinidas, sino que identifica patrones y estructuras ocultas presentes en los datos (Han, Kamber, & Pei, 2012).

Según Jain (2010), el clustering constituye una de las tareas fundamentales de la minería de datos y el reconocimiento de patrones, debido a su capacidad para descubrir segmentos naturales dentro de grandes volúmenes de información (Jain, 2010).

3.2.5.a Aprendizaje no supervisado

El aprendizaje automático no supervisado es una rama del machine learning en la que los algoritmos trabajan con datos que no cuentan con etiquetas ni categorías previas. En lugar de aprender a partir de ejemplos clasificados, estos algoritmos exploran de manera autónoma los datos con el objetivo de descubrir patrones, relaciones y estructuras ocultas que no son evidentes a simple vista.

El aprendizaje no supervisado es útil cuando se desea explorar datos y encontrar agrupamientos sin conocer previamente las clases a las que pertenecen los registros. Esto lo diferencia del aprendizaje supervisado, donde el modelo necesita una variable objetivo conocida (Géron, 2022).

3.2.5.b Distancia y similitud de Clustering

Los algoritmos de clustering se basan en la medición de similitud o distancia entre observaciones. La distancia más utilizada es la Distancia Euclidiana:

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

- x_i y y_i representan los valores de cada variable.
- n es el número de características.

Mientras menor sea la distancia, mayor será la similitud entre dos observaciones.

3.2.5.c Algoritmo K-Means

K-Means es uno de los métodos de agrupamiento más comunes gracias a su facilidad y eficacia. Este método organiza los datos en una cantidad específica de grupos, que son ilustrados por puntos centrales. Cada entrada se destina al grupo cuyo punto central está más próximo.

K-Means busca minimizar la distancia entre los puntos de datos y el centroide del grupo al que pertenecen (MacQueen, 1967). Su función objetivo se expresa de la siguiente manera:

$$J = \sum_{i=1}^k \sum_{x \in C_i} ||x - \mu_i||^2$$

Donde:

- J representa la suma total de errores dentro de los clústeres.
- k es el número de clústeres.
- x representa cada dato.
- C_i es el clúster correspondiente.
- μ_i es el centroide del clúster.

El algoritmo funciona mediante las siguientes etapas:

1. Selección del número de clústeres KKK.
2. Inicialización de centroides.
3. Asignación de cada registro al centroide más cercano.
4. Recalculación de centroides.
5. Repetición hasta la convergencia.

3.2.5.d Algoritmo DBSCAN

El DBSCAN (Density-Based Spatial Clustering of Applications with Noise) es un algoritmo de clustering basado en densidad. A diferencia de otros métodos, este algoritmo identifica grupos de datos a partir de las zonas donde existe una alta concentración de puntos, permitiendo formar clústeres de forma arbitraria y sin necesidad de definir previamente el número de grupos.

(Ester, Kriegel, Sander, & Xu, 1996) propusieron DBSCAN como una alternativa a los métodos tradicionales, especialmente útil cuando los clústeres tienen formas irregulares o cuando existen datos atípicos. El algoritmo utiliza dos parámetros principales:

- ϵ : radio de vecindad alrededor de un punto.
- MinPts: número mínimo de puntos necesarios para formar una región densa.

$$N\varepsilon(p) = \{q \in D \mid \text{dist}(p, q) \leq \varepsilon\}$$

DBSCAN clasifica los registros como:

- Puntos núcleo.
- Puntos frontera.
- Ruido.

3.2.5.e Clustering Jerárquico

El clustering jerárquico construye una estructura de grupos en forma de árbol denominada dendrograma. Según Murtagh y Contreras (2012), el método aglomerativo inicia considerando cada observación como un clúster independiente y posteriormente fusiona los grupos más similares hasta formar una única estructura jerárquica (Murtagh & Contreras, 2012).

La distancia entre clústeres puede calcularse mediante diferentes criterios:

- Single Linkage (Vecino más cercano): El método Single Linkage calcula la distancia entre dos clústeres utilizando la menor distancia existente entre cualquier par de elementos pertenecientes a ambos grupos.

$$D(A, B) = \min_{a \in A, b \in B} d(a, b)$$

- A y B representan dos clústeres.
- $d(a, b)$ es la distancia entre dos observaciones.

Este criterio fusiona los clústeres cuando existe al menos un par de observaciones muy cercanas entre sí.

- Complete Linkage (Vecino más lejano): El método Complete Linkage calcula la distancia entre dos clústeres considerando la mayor distancia entre cualquier par de observaciones pertenecientes a ambos grupos.

$$D(A, B) = \max_{a \in A, b \in B} d(a, b)$$

En este caso, dos grupos solo se fusionan cuando todos sus elementos se encuentran relativamente próximos entre sí.

- Average Linkage (Enlace Promedio): El método Average Linkage calcula la distancia promedio entre todas las observaciones de dos clústeres distintos.

$$D(A, B) = \frac{1}{|A||B|} \sum_{a \in A} \sum_{b \in B} d(a, b)$$

Donde:

- $|A|$ y $|B|$ representan el número de elementos de cada clúster.

A diferencia de Single y Complete Linkage, este método considera la totalidad de los elementos de ambos grupos para calcular la distancia.

3.2.5.f Coeficiente de Silueta (Silhouette Score)

El Coeficiente de Silueta es una métrica propuesta por Rousseeuw (1987) para evaluar la calidad de los agrupamientos generados por un algoritmo de clustering. Su principal ventaja es que mide simultáneamente dos aspectos fundamentales de los clústeres:

- Cohesión: qué tan similares son los elementos dentro del mismo grupo.
- Separación: qué tan diferentes son los elementos respecto a los otros grupos.

Para cada observación se calcula:

- $a(i)$: distancia promedio entre el elemento i y los demás elementos de su mismo clúster.
- $b(i)$: distancia promedio mínima entre el elemento i y los elementos del clúster más cercano.

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

- $s(i)$ es el valor de silueta para la observación i .
- $a(i)$ representa la cohesión.

- $b(i)$ representa la separación.

Valor	Interpretación
Cercano a +1	Excelente agrupamiento
Cercano a 0	Clústeres superpuestos
Cercano a -1	Posible clasificación incorrecta

3.2.5.g Índice Davies-Bouldin

El Índice Davies-Bouldin fue propuesto por Davies y Bouldin (1979) como una medida para evaluar simultáneamente la dispersión interna y la separación entre clústeres.

La idea fundamental consiste en comparar qué tan compactos son los grupos y qué tan alejados se encuentran unos de otros.

$$DB = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \left(\frac{S_i + S_j}{M_{ij}} \right)$$

- k es el número de clústeres.
- S_i es la dispersión interna del clúster i .
- S_j es la dispersión interna del clúster j .
- M_{ij} es la distancia entre los centroides de los clústeres i y j .

Valor	Interpretación
Cercano a 0	Excelente agrupamiento
Bajo	Grupos compactos y separados
Alto	Grupos dispersos y poco diferenciados

3.2.5.h Índice Calinski-Harabasz

El Índice Calinski-Harabasz, también conocido como **Variance Ratio Criterion**, fue desarrollado por Calinski y Harabasz (1974) para evaluar la calidad de una partición mediante el análisis de la varianza entre clústeres y la varianza dentro de los clústeres.

La lógica de esta métrica es sencilla:

- Los grupos deben estar muy separados entre sí.
- Los elementos dentro de cada grupo deben ser muy similares.

$$CH = \frac{Tr(Bk)/(k - 1)}{Tr(Wk)/(n - k)}$$

Donde:

- $Tr(Bk)$ es la dispersión entre clústeres.
- $Tr(Wk)$ es la dispersión dentro de los clústeres.
- k el número de clústeres.
- n el número total de observaciones.

3.3 Definición de términos

3.3.1 Aprendizaje Automático

Rama de la inteligencia artificial que facilita a los sistemas informáticos el aprendizaje a partir de información y la mejora de su rendimiento sin requerir programación específica para cada tarea (Géron, 2022).

3.3.2 Clúster

Conjunto de elementos que comparten características similares entre sí y que, al mismo tiempo, presentan diferencias respecto a los elementos pertenecientes a otros grupos (Han, Kamber, & Pei , 2012).

3.3.3 Variable socioeconómica

Característica medible relacionada con las condiciones sociales y económicas de una persona o grupo, como ingreso familiar, tipo de vivienda, acceso a internet, empleo, procedencia o nivel educativo de los padres, utilizada para analizar diferencias dentro de una población (Han, Kamber, & Pei , 2012).

3.3.4 Métrica de evaluación

Criterio cuantitativo utilizado para medir el rendimiento o la calidad de un algoritmo. En el caso del clustering, permite evaluar la cohesión interna de los grupos y la separación entre clústeres (Rousseeuw, Journal of Computational and Applied Mathematics, 1987).

3.3.5 Toma de decisiones académicas

Proceso mediante el cual una institución educativa utiliza datos, evidencias e indicadores para planificar acciones orientadas a mejorar el rendimiento, acompañamiento, permanencia y bienestar de los estudiantes (Long & Siemens, 2011).

3.3.6 Apoyo institucional

Conjunto de servicios, programas o acciones que ofrece una institución educativa para atender necesidades académicas, económicas, tecnológicas, psicológicas o sociales de sus estudiantes, con el fin de favorecer su desarrollo y permanencia universitaria (Long & Siemens, 2011).

3.3.7 Dataset

Conjunto estructurado de datos organizado en registros y variables, diseñado para facilitar su almacenamiento, procesamiento y análisis mediante técnicas estadísticas y de minería de datos (Han, Kamber, & Pei, 2012).

3.3.8 Codificación de variables

Proceso mediante el cual las variables categóricas son transformadas en representaciones numéricas para que puedan ser procesadas por algoritmos de aprendizaje automático (Géron, 2022).

3.3.9 Perfil socioeconómico

Descripción de un grupo de individuos con características socioeconómicas semejantes, obtenida a partir del análisis conjunto de variables relacionadas con condiciones económicas, sociales, familiares y de acceso a recursos (CEPAL, 2022).

3.3.10 Outlier

Observación cuyos valores difieren significativamente del comportamiento general del conjunto de datos, pudiendo afectar el análisis estadístico y el desempeño de los modelos de aprendizaje automático (Géron, 2022).

4. Metodología

4.1 Tipo y Nivel de Investigación

La investigación es de tipo aplicada: parte de modelos de aprendizaje automático no supervisado y los aplica sobre datos reales de estudiantes de la Universidad Nacional de Moquegua para resolver un problema concreto del contexto institucional, en línea con la definición de Nicomedes (2018). El proyecto implementará algoritmos de agrupamiento para identificar perfiles estudiantiles y con ello orientar decisiones académicas y estrategias de apoyo institucional. (Nicomedes , 2018).

El nivel de investigación es descriptivo-comparativo. La dimensión descriptiva permite caracterizar a los alumnos de la UNAM según sus condiciones sociales y económicas, identificando grupos con rasgos similares; Hernández-Sampieri y Mendoza Torres (2018) señalan que los estudios descriptivos especifican propiedades y características de personas, grupos o procesos bajo estudio. La dimensión comparativa se expresa en la evaluación de tres algoritmos de clustering, K-Means, DBSCAN y agrupamiento jerárquico, para determinar cuál produce la segmentación más adecuada de los datos socioeconómicos.

Asimismo, será comparativo ya que se examinará el rendimiento de varios algoritmos de clustering, como K-Means, DBSCAN y agrupamiento jerárquico, con el objetivo de identificar cuál de estos produce una segmentación más apropiada de la información socioeconómica.

4.2 Diseño de Investigación

El diseño es no experimental ya que los datos se observan en su entorno natural sin que el investigador manipule las variables.

En este estudio, los datos socioeconómicos de los estudiantes se procesarán, limpiarán, codificarán y analizarán mediante algoritmos de agrupamiento, sin ninguna modificación sobre la información original ni sobre las condiciones reales de los estudiantes.

4.3 Operación de variables

La mayoría de trabajos cuando se habla de Inteligencia Artificial tienen un enfoque predictivo, usando variables para predecir otra variable. Esta investigación en cambio se está trabajando con clustering, que es aprendizaje no supervisado. La diferencia clave es que en esta no se busca una variable objetivo clara, sino más bien, es encontrar grupos o perfiles dentro de los datos. Por ende, las variables se están adaptando para que no sea “causa-efecto” de esta manera:

4.3.1 Variable 1

Modelos de clustering: Es una variable técnica, no una independiente causal.

Tabla 2. Variable 1 – Modelos de Clustering

Variable	Dimensión	Indicador Nivel 1	Indicador Nivel 2	Escala
Variable 1: Modelos de Clustering	1. Tipo de modelo	1.1 Algoritmo utilizado	1.1.1 K-Means	Categórica nominal
			1.1.2 DBSCAN	Categórica nominal

2. Rendimiento del modelo	2.1 Validación interna	1.1.3 Clustering Jerárquico	Categórica nominal
		2.1.1 Coeficiente de Silueta	Numérica continua (-1 a 1)
		2.1.2 Índice Davies-Bouldin	Numérica continua
		2.1.3 Índice Calinski-Harabasz	Numérica continua
3. Resultado del modelo	3.1 Agrupamiento obtenido	3.1.1 Número de clústeres generados	Numérica discreta
	3.2 Interpretabilidad	3.2.1 Perfiles socioeconómicos identificados	Categórica nominal

4.3.1.a Dimensiones

- Tipo de modelo

Esta dimensión identifica el algoritmo de agrupamiento usado para la segmentación socioeconómica. Se compararán tres modelos de aprendizaje no supervisado: K-Means, DBSCAN y Clustering Jerárquico, cada uno con un enfoque distinto para formar grupos: por centroides, por densidad y por relaciones jerárquicas entre observaciones, respectivamente (Han, Kamber, & Pei , 2012).

- Rendimiento del modelo

Esta dimensión evalúa la calidad de los agrupamientos mediante métricas de validación interna. Se usarán el Coeficiente de Silueta, que mide cohesión y separación de los clústeres (Rousseeuw, Journal of Computational and Applied Mathematics, 1987); el Índice Davies-Bouldin, que analiza dispersión interna y separación entre grupos (Davies & Bouldin, 1979); y el Índice Calinski-Harabasz, que compara la variabilidad entre clústeres y dentro de ellos (Caliński & Harabasz, 1974).

- Resultado del modelo

Esta dimensión recoge los resultados de cada algoritmo: el número de clústeres generados y la caracterización de los perfiles socioeconómicos identificados, con énfasis en las características predominantes de cada grupo. El criterio de evaluación es si las segmentaciones resultan interpretables y útiles para decisiones institucionales relacionadas con bienestar universitario.

4.3.2 Variable 2

Segmentación perfiles socioeconómicos: Agrupación de los perfiles (estudiantes) según características socioeconómicas similares, con el propósito de identificar perfiles estudiantiles.

Tabla 3. Variable 2 – Características Socioeconómicas

Variable	Dimensión	Indicadores nivel 1	Indicadores nivel 2	Escala
Variable 2: Segmentación de perfiles socioeconómicos	1. Caracterización de perfiles	1.1 Número de perfiles	1.1.1 Cantidad de clústeres obtenidos	Numérica discreta
		1.2 Tipología de perfiles	1.2.1 Perfil con mejores condiciones socioeconómicas	Categórica nominal
			1.2.2 Perfil con condiciones socioeconómicas intermedias	Categórica nominal
			1.2.3 Perfil con mayores limitaciones socioeconómicas	Categórica nominal
	2. Características predominantes de los perfiles	2.1 Condición económica	2.1.1 Nivel de ingreso familiar	Categórica ordinal / Numérica continua
		2.2 Condición familiar	2.2.1 Dependencia económica	Categórica nominal
			2.2.2 Número de integrantes del hogar	Numérica discreta
		2.3 Vivienda y servicios	2.3.1 Condiciones de vivienda	Categórica nominal
			2.3.2 Acceso a servicios básicos	Dicotómica
		2.4 Acceso tecnológico	2.4.1 Acceso a internet	Dicotómica

		2.4.2	Disponibilidad de dispositivos tecnológicos	Dicotómica
		2.5 Transporte	2.5.1 Tiempo de traslado	Numérica continua
			2.5.2 Gasto de transporte	Numérica continua
	3. Utilidad institucional	3.1 Orientación de intervenciones	3.1.1 Perfil orientado a becas	Categórica nominal
			3.1.2 Perfil orientado a apoyo tecnológico	Categórica nominal
			3.1.3 Perfil orientado a tutoría académica	Categórica nominal

4.3.2.a Dimensiones

- Caracterización de perfiles

Esta dimensión describe los perfiles socioeconómicos obtenidos con los algoritmos de clustering: cuántos clústeres se generaron y qué características distinguen a cada grupo, clasificando a los estudiantes según similitudes en sus condiciones socioeconómicas (Alvarez Garcia, Arenas Parra, & Ibar Alonso, 2022).

- Características predominantes de los perfiles

Esta dimensión caracteriza las variables que definen cada perfil socioeconómico identificado. Se analizarán aspectos de condición económica, entorno familiar, vivienda, acceso tecnológico y transporte, para establecer qué atributos predominan en cada clúster y permiten interpretarlo (Han, Kamber, & Pei , 2012).

- Utilidad institucional

Esta dimensión examina cómo los perfiles socioeconómicos identificados pueden orientar decisiones institucionales. Los resultados aportarán información concreta para diseñar programas de becas,

apoyo tecnológico y tutorías académicas dirigidos a los grupos con mayores necesidades (Long & Siemens, 2011).

4.4 Población y Muestra

4.4.1 Población

La población comprende todos los registros de estudiantes de las distintas carreras de la Universidad Nacional de Moquegua, con datos sobre condiciones personales, familiares, económicas, tecnológicas, de vivienda, salud y transporte.

En total se identificaron 10 067 registros y 155 variables, lo que permite un análisis amplio de las condiciones socioeconómicas de los estudiantes.

4.4.2 Muestra

El estudio utilizará una muestra censal, es decir, la totalidad de los elementos de la población accesible (Toaza-Egas, López-Suárez , Vera-Vásquez, & López-Mosquera, 2023).

La muestra quedará conformada por los registros que cumplan criterios básicos de calidad: información completa, coherente y pertinente en las variables seleccionadas para la segmentación socioeconómica.

4.5 Técnicas e instrumentos para la recolección de datos

4.5.1 Técnicas

Esta investigación utilizará técnicas de análisis documental y de bases de datos, ya que se basará en información preexistente en un conjunto de datos sobre la situación socioeconómica de los estudiantes de la Universidad Nacional de Moquegua, específicamente en lo que respecta a aspectos personales, familiares, económicos, tecnológicos, de vivienda, salud y transporte.

El análisis documental facilitará la evaluación y estructuración de la información en el conjunto de datos. Este método implica un examen sistemático de documentos, registros y fuentes existentes para recopilar información relevante sobre el fenómeno en estudio (Arias, 2012). De manera similar, el análisis de bases de datos permitirá el procesamiento, la limpieza, la modificación y la preparación de la información para su uso con algoritmos de agrupamiento. De hecho, en minería de datos, una preparación adecuada de los datos es esencial antes de implementar técnicas de identificación de patrones (Han, Kamber, & Pei , 2012).

Este método se enmarca dentro de los estudios de ciencia e ingeniería de datos, donde el análisis se centra no exclusivamente en el individuo que responde a la encuesta, sino en los datos registrados. Por lo tanto, no se realizarán nuevas encuestas ni entrevistas, ya que la investigación se basa en datos existentes. El trabajo consistirá en la limpieza, selección de variables, codificación, normalización y análisis de registros válidos.

4.5.2 Instrumentos

- Dataset socioeconómica de los estudiantes del 2020 al 2023
- Microsoft Excel
- Lenguaje Python

4.6 Validación de los instrumentos

La investigación está obteniendo de forma directa los datos de la universidad mediante documentación y permisos de la entidad; por ende, no se planea diseñar ni aplicar ningún instrumento de recolección directa de datos a los estudiantes, por lo que la validez del estudio estará relacionada principalmente con la calidad, consistencia e integridad de los registros disponibles.

4.7 Métodos y técnicas para la presentación y análisis de datos

Los datos socioeconómicos proporcionados por la Universidad y provenientes de la Oficina de Asuntos Estudiantiles se recopilarán de forma transparente, de acuerdo con la normativa vigente y los procedimientos administrativos, para segmentar al alumnado según su estatus socioeconómico mediante agrupamiento.

Se utilizarán técnicas analíticas y de aprendizaje automático no supervisado para evaluar los datos. Inicialmente, un análisis preliminar del conjunto de datos identificará su organización, el número de entradas, el número de variables, las categorías de datos, los datos faltantes, los duplicados y las anomalías. Este análisis permitirá identificar las variables relevantes para la clasificación socioeconómica del alumnado de la Universidad Nacional de Moquegua.

Posteriormente, la información se organizará mediante procedimientos de limpieza de datos, selección de características, transformación de variables categóricas y estandarización de variables numéricas. Estos procedimientos son esenciales, ya que los algoritmos de agrupamiento pueden verse afectados por variaciones de escala, datos faltantes o características irrelevantes para el análisis. Finalmente, se implementarán técnicas de agrupamiento, como K-Means, DBSCAN y agrupamiento jerárquico, para crear grupos de estudiantes en función de sus características socioeconómicas. La efectividad de estos métodos se evaluará mediante métricas de validación interna, como el coeficiente de silueta, el índice de Davies-Bouldin y el índice de Calinski-Harabasz, que facilitarán la comparación de la calidad de los grupos resultantes.

Para presentar los resultados, se utilizarán tablas y gráficos derivados del procesamiento de datos para resumir la información más relevante del análisis. Estos recursos permitirán comparar los algoritmos de agrupamiento, las métricas obtenidas y la caracterización de los perfiles socioeconómicos identificados.

Además, durante el análisis de los perfiles socioeconómicos, se examinarán las variables más relevantes para cada grupo. Este paso permitirá describir las características que diferencian a cada grupo de estudiantes, como las variaciones en los ingresos familiares, el acceso a internet, la disponibilidad

tecnológica, los antecedentes, el tipo de vivienda y el transporte. Cuando sea apropiado, se incorporarán métodos de interpretación asociados a la inteligencia artificial explicativa, como el análisis de significancia de variables o el uso de modelos complementarios, para comprender mejor la configuración de los perfiles identificados. Finalmente, los resultados se presentarán de forma comparativa y analítica, facilitando así la selección del algoritmo de agrupamiento más adecuado y la descripción de los perfiles económicos y sociales presentes en el conjunto de datos.

4.8 Propuesta Metodológica

La metodología que se planea seguir en esta investigación es la de Cross-Industry Standard Process for Data Mining (CRISP-DM), metodología que se maneja por 6 fases: Comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación e implementación. CRISP-DM organiza el ciclo de vida de un proyecto de minería de datos en fases que permiten comprender el problema, analizar los datos, preparar la información, construir modelos, evaluar resultados e implementar soluciones (Chapman, 2000).




Ilustración 1. Metodología CRISP-DM

Se aplicarán las fases 2 a 5: comprensión de los datos, preparación de los datos, modelado y evaluación. Se excluye la fase 1 (comprensión del negocio) porque está orientada a proyectos empresariales, y la fase 6 (implementación) porque el estudio no contempla el despliegue de ningún sistema.

4.8.1 Comprensión de los datos

En esta etapa se realiza un análisis exploratorio del conjunto de datos para conocer su organización, contenido y calidad (Chapman, 2000). Se revisará el número de registros y variables disponibles, los tipos de datos presentes y la información vinculada a condiciones personales, familiares, económicas, tecnológicas, de vivienda, salud y transporte de los estudiantes de la Universidad Nacional de Moquegua.

A partir de ese análisis se identificarán las variables candidatas para la segmentación socioeconómica: origen, ingreso familiar, dependencia económica, acceso a internet, disponibilidad de dispositivos tecnológicos, condiciones de vivienda, transporte y estructura familiar. La selección preliminar de variables en esta fase es determinante para la calidad de los agrupamientos posteriores (Han, Kamber, & Pei , 2012).

También se examinarán valores ausentes, registros duplicados, inconsistencias y variables irrelevantes para los objetivos del estudio. Este diagnóstico inicial establece el estado real del conjunto de datos y define las operaciones necesarias en la fase de preparación.

4.8.2 Preparación de los datos

En esta etapa se limpian y ajustan los datos para hacerlos compatibles con los algoritmos de agrupamiento. Primero se seleccionarán las variables socioeconómicas más relevantes, excluyendo identificadores personales, variables con exceso de valores faltantes, datos duplicados y atributos que no aporten a la segmentación (Han, Kamber, & Pei , 2012).

Después se tratarán los valores ausentes, se eliminarán registros duplicados o inconsistentes y se convertirán las variables categóricas a formato numérico. Las variables numéricas se normalizarán o estandarizarán, dado que los algoritmos de clustering son sensibles a diferencias de escala entre atributos (García, Luengo, & Herrera, 2015).

El resultado de esta fase es un conjunto de datos limpio, con los registros válidos y las variables seleccionadas, listo para la etapa de modelado.

4.8.3 Modelado

En esta fase se aplicarán tres algoritmos de agrupamiento sobre el conjunto de datos preparado: K-Means, DBSCAN y clustering jerárquico. Cada uno opera con una lógica distinta: K-Means agrupa por proximidad a centroides (MacQueen, 1967), DBSCAN por densidad de puntos en el espacio (Ester, Kriegel, Sander, & Xu, 1996) y el clustering jerárquico por relaciones de similitud entre observaciones.

Para K-Means se evaluarán distintos valores de k para identificar el número de grupos más adecuado. En DBSCAN se ajustarán los parámetros epsilon y MinPts, que controlan el radio de vecindad y el mínimo de puntos requerido para formar una región densa, lo que también permite detectar registros atípicos. Para el clustering jerárquico se probarán distintos métodos de enlace: Ward, complete, average y single, con el fin de examinar cómo varían las estructuras resultantes según el criterio de agrupación.

El resultado de la fase es un conjunto de segmentaciones socioeconómicas generadas por cada algoritmo, que se contrastarán en la etapa de evaluación (Kaufman & Rousseeuw, 2005).

4.8.4 Evaluación

En esta etapa se mide la calidad de los agrupamientos generados por cada algoritmo mediante tres métricas de validación interna. El coeficiente de silueta cuantifica la cohesión interna de cada clúster y su separación respecto a los demás (Rousseeuw, *Journal of Computational and Applied Mathematics*, 1987). El índice Davies-Bouldin compara la dispersión interna de cada grupo con la distancia entre grupos, donde valores más bajos indican mejor agrupamiento (Davies & Bouldin, 1979). El índice Calinski-Harabasz relaciona la varianza entre clústeres con la varianza interna de cada uno; valores más altos señalan una separación más clara (Caliński & Harabasz, 1974).

Junto a la evaluación numérica, se analizarán los perfiles socioeconómicos resultantes: qué variables predominan en cada clúster y qué características definen a cada grupo de estudiantes. Este paso determina si las segmentaciones son interpretables y útiles para describir la población estudiantil.

Con base en las métricas y la interpretabilidad de los perfiles, se seleccionará el algoritmo que produzca la segmentación más adecuada para los objetivos del estudio (Kaufman & Rousseeuw, 2005).




Ilustración 2. Metodología adaptada para la investigación

5. Aspectos Administrativos

5.1 Cronograma de actividades

Tabla 4. Cronograma de Actividades

N°	Actividades	2026					2027	
		Agosto	Septiembre	Octubre	Noviembre	Diciembre	Enero	Febrero
1	Aprobación del proyecto	X						
1.1	Análisis de los problemas	X						
1.2	Adquisición de material necesario	X						
1.3	Capacitación	X						
2	Comprensión y recopilación de datos		X	X				
2.1	Revisión de variables socioeconómicas		X					
2.2	Análisis exploratorio inicial		X	X				
2.3	Comprensión de la información disponible.		X	X				
3	Preparación de los datos			X	X			
3.1	Limpieza de datos			X				
3.2	Tratamiento de valores faltantes			X	X			
3.3	Codificación de variables categóricas			X	X			
3.4	Normalización			X	X			
3.5	Selección de variables relevantes.			X	X			
4	Construcción de modelos de clustering			X	X	X		
4.1					X	X		

	Implementación de K-Means, DBSCAN y Clustering Jerárquico y ajuste de parámetros y generación de agrupamientos.				x	x		
5	Evaluación e interpretación de resultados				x	x		
5.1	Comparación mediante Silhouette Score, Davies-Bouldin y Calinski-Harabasz				x	x		
5.2	Análisis de perfiles socioeconómicos obtenidos e interpretación de clústeres				x	x		
6	Elaboración del informe final y sustentación					x	x	
6.1	Redacción de resultados, discusión, conclusiones, recomendaciones y revisión final						x	
6.2	Sustentación de tesis							x

5.2 Presupuesto

5.2.1 Recursos Humanos

Tabla 5. Recursos Humanos

Personal	Cantidad	Funciones
Tesista	1	Desarrollar el plan de trabajo correspondiente al proyecto de tesis, cumpliendo con las disposiciones, normas y procedimientos establecidos en el Reglamento de Grados y Títulos de la UNAM
Asesor	1	Brindar orientación al tesista durante el desarrollo de la investigación, supervisando el cumplimiento de los objetivos planteados y verificando la correcta ejecución de las actividades contempladas en el proyecto de tesis.

5.2.2 Bienes y Servicios

Tabla 6. Bienes y Servicios

Tipo	Descripción	Cantidad	Características / Uso
Bien	Computadora	1	Procesador AMD Ryzen 5 8500G, memoria RAM de 16 GB y SSD de 512 GB
	Impresora	1	Impresora multifuncional
	Escritorio (mesa y silla)	1	Mesa + Silla
Servicio	Internet fijo	7 meses	Internet Fijo
	Energía eléctrica	7 meses	Fuente de energía
	Línea telefónica	7 meses	Línea telefónica para realizar llamadas

5.2.3 Plan Presupuestal

Tabla 7. Plan presupuestal

[illegible]

5.2.4 Fuentes de Financiamiento

La investigación será autofinanciada.

6. Bibliografía

Alvarez-Garcia, M., Arenas-Parra, M., & Ibar-Alonso, R. (2024). Uncovering student profiles: An explainable cluster analysis approach to PISA 2022. *Computers & Education*, 223, 105166. <https://doi.org/10.1016/j.compedu.2024.105166>

Antonio Vargas, J. R., & Navarro-Castillo, Y. M. (2025). Clusterización de perfiles emprendedores de estudiantes universitarios en la UNALM: Un análisis con K-Means. *Educación*, 34(66), 113–132. <https://doi.org/10.18800/educacion.202501.A006>

Ester, M., Kriegel, H. P., Sander, J., & Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. En *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining* (pp. 226–231).

Everitt, B. S., Landau, S., Leese, M., & Stahl, D. (2011). *Cluster analysis* (5th ed.). Wiley.

Géron, A. (2022). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems* (3rd ed.). O'Reilly Media.

Han, J., Kamber, M., & Pei, J. (2012). *Data mining: Concepts and techniques* (3rd ed.). Morgan Kaufmann.

Kalita, E., Oyelere, S. S., Gaftandzhieva, S., Rajesh, K. N. V. P. S., Jagatheesaperumal, S. K., Mohamed, A., Elbarawy, Y. M., Desuky, A. S., Hussain, S., Cifci, M. A., Theodorou, P., Hilčenko, S., Hazarika, J., & Ali, T. (2025). Educational data mining: A 10-year review. *Discover Computing*, 28, 81. <https://doi.org/10.1007/s10791-025-09589-z>

MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. En L. M. Le Cam & J. Neyman (Eds.), *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability* (Vol. 1, pp. 281–297). University of California Press.

Peralta Ascue, M., Merma Aroni, J. L., Chavez Vasquez, E., Soto Carrion, C., & Jimenez Mendoza, W. (2022). *Aplicación del algoritmo K-Means en estudiantes universitarios del área de sistemas e informática para caracterizar la salud mental, durante el aislamiento en COVID-19*. En *Memorias de la Vigésima Primera Conferencia Iberoamericana en Sistemas, Cibernética e Informática* (p. 92). <https://doi.org/10.54808/CISCI2022.01.92>

Romero, C., & Ventura, S. (2020). Educational data mining and learning analytics: An updated survey. *WIREs Data Mining and Knowledge Discovery*, 10(3), e1355. <https://doi.org/10.1002/widm.1355>

Rousseeuw, P. J. (1987). *Silhouettes: A graphical aid to the interpretation and validation of cluster analysis*. *Journal of Computational and Applied Mathematics*, 20, 53–65. [https://doi.org/10.1016/0377-0427\(87\)90125-7](https://doi.org/10.1016/0377-0427(87)90125-7)

Siemens, G., & Long, P. (2011). Penetrating the fog: Analytics in learning and education. *EDUCAUSE Review*, 46(5), 30–32.

Siregar, H. L., Hidayanthi, R., & Sakti, A. L. D. (2024). Implementation of K-Means clustering on student learning achievements based on social economic and social related. *Research and Development in Education (RaDEn)*, 4(2), 1447–1459.

Caliński, T., & Harabasz, J. (1974). A dendrite method for cluster analysis. *Communications in Statistics*, 3(1), 1–27. <https://doi.org/10.1080/03610927408827101>

Davies, D. L., & Bouldin, D. W. (1979). A cluster separation measure. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, PAMI-1(2), 224–227.

<https://doi.org/10.1109/TPAMI.1979.4766909>

Esteban Nieto, N. T. (2018). *Tipos de investigación*. Universidad Santo Domingo de Guzmán.

Hernández-Sampieri, R., & Mendoza Torres, C. P. (2018). *Metodología de la investigación: Las rutas cuantitativa, cualitativa y mixta*. McGraw-Hill Education.

Kaufman, L., & Rousseeuw, P. J. (1990). *Finding groups in data: An introduction to cluster analysis*. Wiley. <https://doi.org/10.1002/9780470316801>

Scikit-learn developers. (2026). *Clustering*. Scikit-learn. <https://scikit-learn.org/stable/modules/clustering.html>

CEPAL (2022). *Estudio Económico de América Latina y el Caribe 2022: dinámica y desafíos de la inversión para impulsar una recuperación sostenible e inclusiva*. <https://hdl.handle.net/11362/48077>

PNUD (2023). *Informe Anual 2023*. <https://annualreport.undp.org/2023/es/index.html>

Anil K. Jain (2010). *Data clustering: 50 years beyond K-mean*. https://biometrics.cse.msu.edu/Publications/Clustering/JainClustering_PRL10.pdf

Murtagh, F. and Contreras, P. (2012), *Algorithms for hierarchical clustering: an overview*. WIREs Data Mining Knowl Discov, 2: 86-97. <https://doi.org/10.1002/widm.53>

Kotler, P. and Keller, K. (2012) *Dirección de marketing – Decimocuarta edición*. <https://www.montartuempresa.com/wp-content/uploads/2016/01/direccion-de-marketing-14edi-kotler1.pdf>

García, S., Luengo, J., & Herrera, F. (2015). *Data preprocessing in data mining* (Intelligent Systems Reference Library, Vol. 72). Springer. <https://doi.org/10.1007/978-3-319-10247-4>

Kaufman, L., & Rousseeuw, P. J. (2005). *Finding groups in data: An introduction to cluster analysis*. Wiley-Interscience. <https://doi.org/10.1002/9780470316801>

7. ANEXO

MATRIZ DE CONSISTENCIA

AUTOR: LEO ENRIQUE PARI PUMA

TITULO	Segmentación de perfiles socioeconómicos en estudiantes mediante modelos de clustering para apoyar la toma de decisiones institucionales en la Universidad Nacional de Moquegua, 2026.			
FORMULACIÓN DEL PROBLEMA	OBJETIVOS	VARIABLES	DIMENSIONES	INDICADORES
INTERROGANTE GENERAL: ¿Cuál es el modelo de clustering más adecuado para la segmentación de perfiles socioeconómicos de los estudiantes de la Universidad Nacional de Moquegua, 2026?	OBJETIVO GENERAL: Comparar algoritmos de clustering aplicados a la segmentación socioeconómica de los estudiantes de la Universidad Nacional de Moquegua, con el fin de identificar perfiles estudiantiles.	VARIABLE 1 Modelos de Clustering	1. Configuración del modelo	1.1. Selección del algoritmo
			2. Construcción del modelo	1.2. Parámetros del algoritmo
				2.1. Generación de clústeres
			3. Evaluación del modelo	2.2. Tiempo de procesamiento
INTERROGANES ESPECIFICAS: IE1. ¿Cuál es el desempeño de los modelos de clustering para la segmentación de perfiles socioeconómicos de los estudiantes de la Universidad Nacional de Moquegua, considerando las métricas de validación interna (coeficiente de silueta, índice Davies-Bouldin e índice Calinski-Harabasz)? IE2. ¿Qué perfiles socioeconómicos pueden identificarse a partir de la segmentación de la ficha socioeconómica de los estudiantes de la Universidad Nacional de Moquegua para apoyar la toma de decisiones institucionales?	OBJETIVOS ESPECIFICOS: OE1. Construir y evaluar modelos de clustering para la segmentación de perfiles socioeconómicos de los estudiantes de la Universidad Nacional de Moquegua, mediante la aplicación de métricas de validación interna como el coeficiente de silueta, el índice Davies-Bouldin y el índice Calinski-Harabasz. OE2. Identificar los perfiles socioeconómicos de los estudiantes de la Universidad Nacional de Moquegua mediante la aplicación de modelos de clustering sobre la ficha socioeconómica, con el fin de apoyar la toma de decisiones institucionales.	VARIABLE 2 Segmentación de perfiles socioeconómicos	1. Caracterización de perfiles	3.1. Coeficiente de Silueta
			2. Composición socioeconómica	3.2. Índice Davies-Bouldin
				3.3. Índice Calinski-Harabasz
				1.1. Número de perfiles
				1.2. Tamaño de los perfiles
				2.1. Características sociodemográficas
				2.2. Condición económica
			3. Interpretación de perfiles	2.3. Condición familiar
				2.4. Vivienda y servicios básicos
				2.5. Acceso tecnológico
				2.6. Transporte y accesibilidad
				3.1. Perfil con mejores condiciones
				3.2. Perfil intermedio
3.3. Perfil con mayores limitaciones				
TIPO, NIVEL Y DISEÑO DE INVESTIGACIÓN	POBLACIÓN Y MUESTRA	TECNICAS E INSTRUMENTOS		
Tipo aplicada, de nivel descriptivo – comparativo y diseño no experimental	POBLACIÓN: Registros socioeconómicos de estudiantes de la UNAM (aprox. 10,067 registros y 155 variables, del 2020 al 2023). MUESTRA: Muestra censal: totalidad de registros válidos que cumplan criterios de calidad e integridad para el análisis de clustering.	TECNICAS: Las técnicas de análisis documental y análisis de base de datos serán las utilizadas para esta investigación debido a que se trabajará con información previamente registrada en un dataset que contiene datos relacionados con características personales, familiares, económicas, tecnológicas, de vivienda, salud, transporte y otros aspectos vinculados a la situación socioeconómica de los estudiantes de la UNAM. INTRUMENTOS: - Dataset socioeconómica de los estudiantes - Microsoft Excel - Lenguaje Python		